UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de Ingeniería

Laboratorio 6

Gabriela Mazariegos
José Santiago Pereira
Brandon Javier Reyes

Task 1

1. Un desarrollador junior de su equipo sugiere: *"Para detectar con mayor precisión las texturas de las hojas enfermas, deberíamos construir una red secuencial clásica (tipo VGG) pero de 150 capas. Más profundo siempre es mejor"*. Como líder técnico, **explíquele** argumentativamente por qué esta red fracasará estrepitosamente en el entrenamiento (mencionando el fenómeno de degradación y el desvanecimiento del gradiente). Luego, **justifique** cómo la adición estructural de las conexiones residuales ($F(x) + x$) de **ResNet** rescata el proyecto, haciendo viable entrenar redes ultra-profundas sin colapsar.

R// En este caso debería de rechazar la propuesta de construir una red VGG de 150 capas, ya que fallaría por problemas en el proceso de la red neuronal. El primer problema es el desvanecimiento del gradiente, recordemos que durante backpropagation, el gradiente se calcula como un producto encadenado de derivadas parciales a través de todas las capas, y con 150 capas ese producto se aproxima exponencialmente a cero, dejando las capas iniciales sin aprender nada útil ya que sería insignificante el valor debido a que se aproxima a cero. El segundo problema es la degradación: En diferentes estudios se han demostrado que agregar capas a una red plain aumenta el error en entrenamiento, porque el optimizador no puede aprender ni siquiera la función identidad debido a tantas transformaciones que sufre en el proceso.

Por otro lado, ResNet soluciona estos problemas mediante sus conexiones residuales, en lugar de que cada bloque aprenda la transformación completa desde cero, solo aprende la diferencia respecto a la entrada original, que se suma directamente a la salida. Teniendo en cuenta esto entonces propondría utilizar esta arquitectura ya que nos evita el problema principal del desvanecimiento.

Task 1.2

2. Las enfermedades en las hojas de mango son visualmente heterogéneas: La *Antracnosis* se presenta como puntos negros diminutos, mientras que el *Moho Polvoriento* cubre áreas enormes de la hoja. **Analice** cómo la topología en paralelo del módulo Inception (usando filtros 3x3 y 5x5 simultáneamente) es ideal para este problema biológico en particular. Además, desde una perspectiva de costos de infraestructura (uso de GPUs en AWS o Google Cloud), **explique** cómo la inserción estratégica de convoluciones de 1x1 evita la explosión de la dimensionalidad y salva el presupuesto mensual de la startup.

R// Para el primer punto es bastante simple, si nosotros tomamos un kernel de dimensiones fijas, por ejemplo 3x3, este va a poder distinguir de forma correcta la antracnosis pero no el moho, ya que podría captura las características pequeñas y no grandes como la del moho y viceversa con un kernel mas grande, pero utilizando la topología en paralelo del módulo

inception nosotros podemos ser capaces de, en este caso en específico el poder percibir y detectar estas características tanto del moho como de la antracnosis sin problema. Por otro lado el hecho de usar convoluciones de 1x1 para evitar el presupuesto alto por mes alojado en algún servicio de la nube también es bastante simple, si nosotros tomamos por ejemplo una entrada grande de 256 con un kernel de 5 x 5 y por ejemplo n cantidad de filtros se tendrían aproximadamente 6400 * n parámetros por capa, lo cual sería demasiado, pero tomando un kernel que actúa como cuello de botella de 1 x 1 la cantidad de parámetros se reduciría drásticamente y por ende se tendría menos consumo de recursos de la nube en el entrenamiento y procesamiento del modelo y por ende menos gasto mensual.

Task 1.3

3. El cliente final (el agricultor) usará la aplicación en un teléfono Android de gama baja en medio del campo, sin conexión a internet. Sabemos que MobileNet logra esta eficiencia gracias a la Depthwise Separable Convolution. **Describa** brevemente cómo esta convolución divide el trabajo (filtrado espacial vs. combinación de canales). Sin embargo, en ingeniería no hay soluciones mágicas, todo

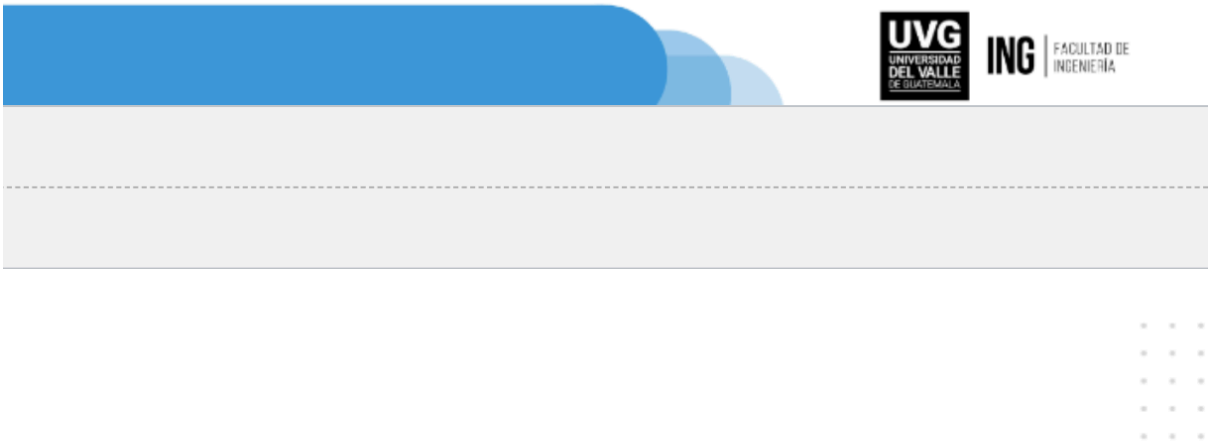

tiene un precio: ¿Qué capacidad matemática o expresividad de la red se está sacrificando al separar estos dos pasos en comparación con una convolución estándar? **Analice** críticamente por qué, como director del proyecto, usted acepta pagar ese "costo" en este escenario comercial.

R// Al aceptar la Depthwise en teoría, sacrificamos capacidad para modelar interacciones complejas espacio–canal; en la práctica, estamos intercambiando una pequeña porción de precisión por viabilidad.

El punto clave no es solo que el modelo sea más rápido, sino que habilita un caso de uso que de otra forma no existiría. En un entorno rural, sin conectividad y con hardware limitado, un modelo más preciso pero inviable no compite realmente: queda descartado desde el inicio. Por tanto, la comparación justa no es “más preciso vs menos preciso”, sino “solución usable

vs solución inutilizable” entonces teniendo en cuenta esto veo viable el hecho de utilizar Depthwise.